Année Universitaire : 2026/2027		Machine Learning I
ING2-BDML	PARIS PANTHÉON-ASSAS UNIVERSITÉ	Resp : Ahmed Ghazi BLAIECH / Ahmad Tay / Hassan Shraim

Projet de Machine Learning

Contexte : Ce projet vise à mettre en place un système de maintenance prédictive pour les machines de l'usine et à analyser les causes qui font que la condition de la valve d'un cycle de production est non optimale parfois.

Objectif : Construisez un modèle ML pour prédire si la condition valve est optimale (=100%) ou non, pour chaque cycle. Vous utiliserez les 2000 premiers cycles pour construire le modèle et le reste comme échantillon de test final.

Données : Les données sont disponibles dans [lien]. Les données sont décrites dans [lien] à utiliser uniquement les 3 fichiers suivants, chaque ligne représentant un cycle :

- PS2 (Pression (bar) échantillonnage 100Hz)
- FS1 (Volume flow (l/min) échantillonnage 10Hz)
- Profile : Fichier avec les variables dont la "valve condition" qui nous intéresse.

Méthodologie du projet:

1. Prétraitement des données

- Chargement des données et statistiques descriptives.
- Gestion des valeurs manquantes et détection des valeurs aberrantes.
- Encodage correct des variables catégorielles (si présentes).
- Transformation du problème en classification binaire.
- Analyse de la distribution des classes pour vérifier l'équilibre du jeu de données.
- Analyse des corrélations entre les variables.
- Visualisations (matrice de corrélation, histogrammes, boxplots).
- Utilisation de méthodes de sélection de variables (Features selection).

2. Modélisation et évaluation

- Modèles envisagés : régression logistique, k-NN, arbre de décision, Naive Bayes, SVM, ensemble learning.
- Justification du choix des modèles selon :
  - Leurs propriétés théoriques (linéaires vs non linéaires).
  - Leur adaptabilité au type de données (distributions continues, bruit, etc.).

3. Évaluation des modèles

- Évaluation des modèles à l'aide de métriques pertinentes :
    - Accuracy, précision, rappel, F1-score.
    - Matrice de confusion.
    - Courbe ROC et AUC.
- Comparaison des performances et interprétation des résultats.
- Identification du modèle le plus performant selon un compromis biais/variance.

4. Optimisation des hyperparamètres

- Utilisation de techniques d'optimisation telles que :
    - Grid Search : recherche exhaustive sur une grille d'hyperparamètres.
    - Random Search : recherche aléatoire pour un gain de temps.
- Évaluation des modèles optimisés via validation croisée (k-fold).

Bonus : Voici quelques points bonus que vous pouvez choisir de réaliser en plus :

- Mettre votre solution sur github ou gitlab
- Ajouter des tests unitaires
- Containeriser votre code pour qu'il être exécuté facilement par un tiers
- Mettre en place une application web qui donne la prédiction pour un numéro de cycle donné en entrée

Livrables attendus

- Rapport technique détaillant les étapes de traitement, d'analyse et de modélisation.
- Notebook Python (Jupyter/Colab) contenant le code complet.